Caderno Técnico do Docente — Encontro 2

Fundamentos Matemáticos, Ciência da Computação e Arquitetura Neural por Trás de Cada Slide

Público-alvo deste documento: Professores, instrutores e coordenação que precisam **dominar a ciência e a matemática** por trás do curso antes de traduzi-la didaticamente para os alunos.

📑 Índice de Tópicos Críticos

1. Slide 4: A Mecânica de Busca vs. A Concatenação Auto-regressiva
2. Slide 5: Onde Fica o Conhecimento? (Pesos Sinápticos vs. Bancos de Dados)
3. Slide 6: Teoria da Tokenização (BPE, Vocabulário e Espaço Vetorial)
4. Slide 7: A Matemática da Predição (Fórmula, Logits, Softmax e Temperatura)
5. Slide 8: Entropia de Shannon e o Colapso da Árvore Amostral
6. Slide 9: A Revolução de 2017 e a Equação da Autoatenção (Transformers)
7. Slide 10: Multi-Head Attention e Densidade de Atenção em Prompts Estruturados
8. Slides 11 a 13: A Física da Alucinação (Ruído, Desvio Latente e a Função de Perda)
9. Slides 15 a 17: Condicionamento de Priors e Redução do Espaço Amostral
10. Slides 18 e 19: Mecanismo de In-Context Learning no Few-Shot
11. Slides 20 e 21: Por Que o Chain of Thought (CoT) Funciona Computacionalmente?
12. Slides 24 a 27: A Ciência de Dados Ética: Vieses Algorítmicos e Dora Kaufman
13. Slide 32: O Embasamento Científico dos Artigos Citados (ArXiv e PMC)

---

1. Slide 4: A Mecânica de Busca vs. A Concatenação Auto-regressiva

Como funciona um Buscador (ex: Google tradicional)?

Um buscador opera sobre uma estrutura estática de dados chamada **Índice Invertido** (*Inverted Index*): * Na internet, bilhões de páginas são varridas por *crawlers*. O texto é limpo e mapeia-se cada palavra a uma lista de documentos onde ela aparece: undefined * Quando você faz uma busca, o algoritmo cruza essas listas usando métricas estatísticas de frequência (como **BM25** ou **TF-IDF**) e calcula a relevância e autoridade das páginas via **PageRank** (um cálculo de autovetor sobre a matriz estocástica de hiperlinks da web). * **Conclusão:** O buscador apenas **recupera e**

ordena páginas existentes escritas por seres humanos. Se a página não existe, ele não tem o que entregar.

Como funciona a LLM (Concatenação Direta)?

Uma LLM não tem índice invertido nem vasculha a web durante o processo padrão de inferência: * O modelo recebe o seu prompt como uma **sequência de entrada** $X = (x_1, x_2, \ldots, x_T)$. * Ele anexa (concatena) esses tokens em um vetor contínuo de contexto. * O modelo não executa buscas em disco: ele realiza uma série massiva de multiplicações de matrizes em ponto flutuante dentro da GPU (**Forward Pass**). * **Conclusão:** Cada token gerado é uma síntese estatística em tempo real, condicionado a todo o bloco concatenado que veio antes dele.

---

2. Slide 5: Onde Fica o Conhecimento? (Pesos Sinápticos vs. Bancos de Dados)

O que são "Pesos Matemáticos" (*Weights*)?

Quando dizemos que o modelo "aprendeu biologia", onde está essa informação? * Ela está armazenada em matrizes gigantescas de números decimais (float16 ou bfloat16, ocupando 2 bytes por número). * Um modelo de 70 bilhões de parâmetros possui 70 bilhões dessas conexões numéricas distribuídas em camadas de: 1. **Matrizes de Projeção de Atenção:** W_Q, W_K, W_V, W_O. 2. **Matrizes de Redes Neurais Feed-Forward (MLP/FFN):** W_1, W_2, W_3 (onde a maior parte da memória factual de padrões fica gravada). * Durante o pré-treinamento, através do algoritmo de retropropagação do erro (*Backpropagation*) com otimizadores como o **AdamW**, o modelo ajusta esses números para minimizar o erro de previsão. * **O Conhecimento é Paramétrico:** É uma compressão matemática com perdas (*lossy compression*) de petabytes da internet. Por isso a IA não guarda o texto exato da Wikipedia, mas a capacidade de reconstituir a probabilidade das palavras daquele domínio. * **O Teste do Cabo Desconectado:** Como todo o conhecimento está codificado nessas matrizes de parâmetros na memória da GPU (VRAM), a inferência é 100% autônoma e off-line.

---

3. Slide 6: Teoria da Tokenização (BPE, Vocabulário e Espaço Vetorial)

Como o texto vira número? (O Algoritmo BPE - Byte-Pair Encoding)

A máquina não opera com strings nem com caracteres ASCII isolados: 1. **Criação do Vocabulário:** Antes do treino da IA, pega-se um corpus gigantesco de texto e aplica-se o algoritmo **BPE**: * Começa-se com caracteres individuais. * Contam-se os pares mais frequentes (ex: `"e"` + `"m"` $\rightarrow$ `"em"`; `"t"` + `"e"` $\rightarrow$ `"te"`). * Esses pares são fundidos iterativamente até que se atinja um

vocabulário fixo pré-determinado $|V|$ (geralmente entre 32.000 e 128.000 tokens, como no *tiktoken cl100k_base* da OpenAI). 2. **Tokenização:** * A palavra `"casa"` é muito comum no treino: vira 1 único token com ID numérico, por exemplo, `15243`. * A palavra `"desoxirribonucleico"` não é um token único: é fatiada em subpalavras: `["des", "oxi", "rribo", "nucle", "ico"]`. 3. **Embeddings (Espaço Vetorial Contínuo):** * O ID do token (ex: `15243`) entra em uma matriz de consulta chamada **Embedding Layer** ($E \in \mathbb{R}^{|V| \times d_{model}}$). * O número inteiro se transforma em um vetor denso de centenas ou milhares de dimensões (ex: $d_{model} = 4096$ floats). * Neste espaço vetorial multidimensional, palavras semântica ou sintaticamente afins apontam para direções geométricas vizinhas: $$\cos(\vec{v}*{|text{rei}} - |vec{v}*{\text{homem}} + \vec{v}*{|text{mulher}}, |vec{v}*{\text{rainha}}) \approx 1$$

---

4. Slide 7: A Matemática da Predição (Fórmula, Logits, Softmax e Temperatura)

A Equação Fundamental da Predição Auto-regressiva

No telão do Slide 7 é apresentada a fórmula de probabilidade condicional:

$$P(w_n \mid w_1, w_2, \ldots, w_{n-1})$$

Como essa probabilidade é calculada na última camada da rede?

1. **A Camada de Logits:** * Após o vetor de contexto passar por todas as camadas do Transformer (geralmente 32 a 80 blocos residuais), a rede gera um vetor latente final $h_n \in \mathbb{R}^{d_{model}}$. * Esse vetor é multiplicado pela matriz do vocabulário transposta (**Unembedding Layer**):

$$z = h_n \cdot W_U$$

   * O resultado é um vetor bruto $z \in \mathbb{R}^{|V|}$ chamado de **Logits**. * Cada uma das 100.000 posições do vetor z contém um número real arbitrário (positivo ou negativo, ex: 14.2, -3.1, 0.8), representando a pontuação bruta de cada token do dicionário.

2. **A Função Softmax com Temperatura (T):** * Como transformar números brutos arbitrários em uma distribuição de probabilidade válida (onde todos os valores fiquem entre 0 e 1 e somem exatamente 100%)? * Aplica-se a função **Softmax normalizada**:

$$P(w_i) = \frac{e^{z_i / T}}{\sum_{j=1}^{|V|} e^{z_j / T}}$$

3. **O Papel Físico da Temperatura (T):** * **Se $T = 1.0$ (Padrão):** O modelo usa as probabilidades originais calculadas pelas camadas neurais. * **Se $T \to 0$ (Temperatura Baixa, ex: 0.1 ou Argmax**

/ Greedy Search):
O denominador acentua brutalmente a maior pontuação. A maior probabilidade vai para $\approx 99.9\%$, tornando a resposta **estritamente determinística**, previsível e rígida (ideal para código e cálculos). * **Se $T > 1.0$ (Temperatura Alta, ex: 1.5):**
A divisão por T reduz as diferenças entre os logits. A curva exponencial se achata. Tokens raros e improváveis ganham chance real de serem sorteados, aumentando a "criatividade", mas disparando as alucinações e erros gramaticais.

4. **Filtros de Amostragem (Top-K e Top-P):** * **Top-K:** Descarta tudo fora dos K tokens mais prováveis (ex: $K = 40$). * **Top-P (Nucleus Sampling):** Ordena os tokens e soma suas probabilidades até atingir um limiar acumulado P (ex: 90%). Descarta a "cauda longa" de palavras absurdas.

---

5. Slide 8: Entropia de Shannon e o Colapso da Árvore Amostral

Por que pedidos genéricos produzem respostas clichês?

Na Teoria da Informação de Claude Shannon, a **Entropia** mede o nível de incerteza de uma distribuição de probabilidade:

$$H(X) = -\sum_{i} P(x_i) \log_2 P(x_i)$$

- **No "Pedido Simples" (*"Faça um plano de aula sobre água"*):**
- A entropia condicional de entrada é baixíssima (você entregou quase zero bits de restrição).
- Como a rede não tem como saber o nível da turma nem o tempo, a distribuição de probabilidade $P(w_n)$ para o próximo token fica espalhada (alta entropia).
- O modelo converge para o atrator estatístico central do corpus de treino: a média genérica de textos sobre água da internet.
- **No Prompt Estruturado (*"Para o 9º ano, 50 min, metodologia ativa, semiárido"*):**
- Cada restrição condiciona os vetores latentes. A incerteza despenca (baixa entropia).
- Os logits associados a vocabulários infantis ou universitários recebem pontuação negativa na atenção, e a probabilidade colapsa exclusivamente nos termos pedagógicos necessários.

---

6. Slide 9: A Revolução de 2017 e a Equação da Autoatenção (Transformers)

1. O que é o "Marco Científico de 2017"?

Antes de 2017, a inteligência artificial processava linguagem natural com **Redes Neurais Recorrentes (RNN)** e **LSTMs (Long Short-Term Memory)**: * **O Problema das RNNs:** Elas processavam texto sequencialmente, palavra por palavra:

$$h_t = \tanh(W x_t + U h_{t-1})$$

* **Gargalos Fatais:** 1. *Impossibilidade de Paralelização:* O token 100 não podia ser processado sem antes calcular os tokens 1 a 99. Isso impedia treinar modelos em milhares de GPUs ao mesmo tempo. 2. *Esquecimento Catastrófico e Vanishing Gradient:* As relações de longo alcance se perdiam ao longo da cadeia temporal. Ao chegar no fim de um parágrafo, a influência do início havia evaporado. * **A Ruptura:** Em 2017, Ashish Vaswani e uma equipe de 7 cientistas do Google Brain publicaram o artigo *"Attention Is All You Need"*. Eles eliminaram a recorrência e propuseram uma arquitetura baseada **exclusivamente em atenção**: o **Transformer**.

2. O que significa o "T" de ChatGPT?

- **Chat:** A interface conversacional.
- **G (Generative):** Gera novos dados auto-regressivamente a partir de distribuições de probabilidade.
- **P (Pre-trained):** Foi pré-treinado em regime não supervisionado em petabytes de texto para prever a próxima palavra.
- **T (Transformer):** A arquitetura neural baseada em autoatenção paralela criada em 2017.

3. A Matemática da Autoatenção (Scaled Dot-Product Attention)

O núcleo computacional do Transformer é calculado pela fórmula:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Para entender isso sem mistério: * Toda palavra entra na camada e é projetada em 3 vetores diferentes por matrizes treináveis: * Q **(Query - Consulta):** "O que este token está procurando no restante da frase?" * K **(Key - Chave):** "O que este token tem a oferecer de contexto ou conteúdo?" * V **(Value - Valor):** "Qual é a informação real que este token carrega?" * **O Produto Escalar (QK^T):** Multiplica a Query de cada palavra pelas Keys de todas as outras palavras. Se os vetores apontam na mesma direção, o resultado é um número alto (alta similaridade semântica). * **A Divisão por $\sqrt{d_k}$:** Escala os números para evitar que vetores de dimensões altas (ex: $d_k = 64$ ou 128) gerem valores extremos, o que saturaria a função Softmax com gradientes quase nulos. * **O**

Resultado: Uma matriz de pesos onde cada célula indica a porcentagem de atenção que a palavra da linha deve dar à palavra da coluna.

4. O que é a Desambiguação Contextual?

A língua humana é repleta de palavras polissêmicas (com múltiplos sentidos). A autoatenção resolve isso matematicamente: * Caso A: *"Fui ao **banco** depositar um cheque."* * A Query do token `"banco"` cruza com a Key de `"cheque"` e `"depositar"`. O produto escalar $Q_{\text{banco}} \cdot K_{\text{cheque}}$ explode positivamente. * O peso de atenção atribuído a `"cheque"` e `"depositar"` fica próximo de 0.85. * Quando essa atenção multiplica a matriz V (Value), o vetor resultante de `"banco"` nesta camada é puxado para o agrupamento vetorial de "instituição financeira". * Caso B: *"Sentei no **banco** da praça."* * A Query de `"banco"` cruza com as Keys de `"sentei"` e `"praça"`. * O vetor de `"banco"` é puxado para o subespaço vetorial de "mobiliário urbano/assento de madeira".

---

7. Slide 10: Multi-Head Attention e Densidade de Atenção em Prompts Estruturados

O que são Múltiplas Cabeças de Atenção (*Multi-Head Attention*)?

Em vez de calcular uma única matriz de atenção, os modelos modernos utilizam dezenas de **cabeças de atenção em paralelo** (ex: 32 a 96 cabeças):

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

* Cada cabeça de atenção especializa-se em um fenômeno linguístico diferente: * Uma cabeça monitora concordância gramatical (sujeito e verbo). * Outra monitora referências pronominais (*"ele"*, *"ela"*, *"isso"*). * Outra monitora restrições e delimitadores de prompt.

Por que prompts estruturados funcionam melhor fisicamente?

- Quando o prompt é um bloco único desordenado, as cabeças de atenção dispersam seus pesos em termos adjetivos, redundâncias e conectivos.
- Quando o prompt usa títulos, delimitadores e tópicos numerados:
- Tokens de quebra estrutural (como `\n`, `###`, `-`) ativam cabeças especializadas em controle sintático.
- As regras fixadas nos tópicos de restrição mantêm pesos de atenção ativos ao longo de todas as camadas profundas, impedindo que o modelo "esqueça" as regras de saída.

---

8. Slides 11 a 13: A Física da Alucinação (Ruído, Desvio Latente e a Função de Perda)

1. O Caso do Erro de Digitação: Por que `A4899` em vez de `A4988` é desastroso?

- O termo correto `A4988` é um chip consagrado na robótica. Durante o treino, o par `A4988` foi associado a milhares de datasheets contendo os termos `"Allegro Microsystems"`, `"motor de passo"`, `"pinos STEP e DIR"`. Seus vetores têm representações factuais consolidadas.
- O termo inexistente `A4899` é fatiado pelo tokenizador em fragmentos desconhecidos (ex: `["A4", "899"]`).
- A Query desse token procura correspondências na memória paramétrica e **não encontra nenhuma chave (K) compatível**.
- A atenção se ancora em vizinhos vagos (como chips da família `A4xxx`).
- Como a rede neural **não tem um estado de saída vazio (ela não silencia)**, a camada Softmax gera uma previsão de continuação mais plausível para aquele subespaço arbitrário.

2. O Efeito Dominó Auto-regressivo

Por que uma alucinação começa pequena e vira um delírio completo? * Lembre-se: todo token gerado no instante t é **anexado à entrada** no instante $t+1$:

$$\text{Entrada}_{t+1} = [\text{Prompt}, w_1, w_2, \ldots, w_t]$$

* Se w_1 foi um desvio gerado por um erro de digitação, a partir de w_2 o modelo assume que w_1 é um fato verdadeiro fornecido pelo contexto! * A máquina calcula as probabilidades sobre uma premissa corrompida. Ela inventa pinagens, leis e dados com lógica impecável, porque está apenas minimizando a incoerência do texto que ela mesma acabou de escrever.

3. A Função de Perda (*Cross-Entropy Loss*) vs. A Verdade Empírica

Por que a IA mente com tanta convicção? * Durante o treino, a função de perda avalia apenas a entropia cruzada entre a palavra prevista e a palavra real do texto de treino:

$$\mathcal{L} = -\sum_{i=1}^{|V|} y_i \log(\hat{y}_i)$$

* O modelo aprendeu a **reproduzir a sintaxe e a estrutura discursiva de especialistas**. **Ele não tem senso**s no mundo real, não tem acesso ontológico à verdade física. Ele é treinado para que o texto **pareça verdadeiro**. * O alinhamento via **RLHF (**inforcement Learning from Human Feedback)** agravou esse problema: como avaliadores humanos tendem a dar notas altas para respostas educadas, completas e sem hesitação, a IA foi reforçada para nunca dizer "não sei", preferindo fabular com autoridade gramatical.

9. Slides 15 a 17: Condicionamento de Priors e Redução do Espaço Amostral

O que o Papel (*Role-Oriented*) faz matematicamente?

Em termos bayesianos, o papel atua como uma atualização dramática da distribuição a priori (*prior*):

$$P(\text{vocabulário} \mid \text{Role} = \text{'Coordenador Pedagógico BNCC'})$$

* Sem o papel, a probabilidade $P(w)$ abrange todo o espectro da internet (gírias de fóruns, textos amadores, linguagem publicitária). * Com o papel, os pesos de projeção ativam quase que exclusivamente os agrupamentos semânticos relativos à literatura técnica e aos documentos normativos daquela profissão.

O que a Tarefa com Limites Negativos (*Task & Bounds*) faz?

- Comandos abertos deixam o espaço amostral sem barreiras.
- Limites negativos (*"Não sugira celulares", "Máximo de 2 horas", "Em formato de tabela"*) colocam vetores de repressão que forçam os logits indesejados a receberem pontuações fortemente negativas na camada final, eliminando a prolixidade na raiz.

10. Slides 18 e 19: Mecanismo de In-Context Learning no Few-Shot

Como o modelo aprende com 2 exemplos sem ser reprogramado?

Descoberto em 2020 por Brown et al. (GPT-3), o **In-Context Learning (ICL)** foi uma das capacidades emergentes mais impressionantes da história da IA: * O modelo não atualiza nenhum peso sináptico durante a inferência (os gradientes estão congelados). * Pesquisas recentes (von Oswald et al., 2023; Dai et al., 2023) comprovaram que as camadas de autoatenção do Transformer realizam implicitamente uma forma de **descida de gradiente dentro do próprio contexto**. * Ao observar os pares `[Entrada 1 → Saída 1]` e `[Entrada 2 → Saída 2]`, os holofotes de atenção extraem o vetor de transformação funcional da tarefa. * Quando a nova entrada é apresentada, o modelo aplica essa mesma transformação linear no espaço latente. * **Resultado prático:** O Few-Shot calibra a métrica de avaliação, a extensão da resposta e a pontuação com precisão cirúrgica sem necessidade de código.

11. Slides 20 e 21: Por Que o Chain of Thought (CoT) Funciona Computacionalmente?

O que a ciência descobriu sobre o "Pense Passo a Passo"?

No artigo clássico de Wei et al. (2022, Google Research), a introdução do Chain of Thought transformou o raciocínio das LLMs. Mas por que isso acontece matematicamente?

1. **A Limitação da Passagem Direta (*Forward Pass Fixo*):** * Uma rede neural tem uma profundidade fixa L (ex: 32 camadas). * Em uma pergunta matemática ou de lógica complexa, se você pede a resposta direta, o modelo tem apenas **uma única passagem direta** através dessas 32 camadas para calcular o resultado. * Se a quantidade de computação necessária para deduzir a lógica exigir mais etapas funcionais do que as camadas físicas disponíveis, a rede é matematicamente forçada a chutar uma resposta baseada na semelhança superficial do texto.

2. **A Alavancagem Computacional do Chain of Thought:** * Quando o modelo emite o primeiro token de raciocínio intermediário (*"Passo 1: 45% de 120 é 54"*), ele executa um forward pass completo de 32 camadas para chegar a essa premissa. * Em seguida, para calcular o próximo passo, **toda a rede de 32 camadas é acionada novamente**, agora tendo o Passo 1 gravado como contexto na memória! * **Conclusão:** O Chain of Thought converte uma rede de profundidade fixa em um sistema com **tempo de computação dinâmico**. Quanto mais passos ele escreve, mais poder computacional ele dedica à resolução do problema antes de emitir a resposta final!

---

12. Slides 24 a 27: A Ciência de Dados Ética: Vieses Algorítmicos e Dora Kaufman

O que Dora Kaufman (PUC-SP) ensina sobre o Protagonismo dos Algoritmos?

A professora e pesquisadora Dora Kaufman (Laboratório TECCOGS / PUC-SP) é uma das maiores referências brasileiras em ética de IA: 1. **A Falsa Neutralidade da Matemática:** * Modelos de machine learning aprendem por indução empírica. Se os dados históricos de treinamento contêm racismo, machismo, desigualdade regional e exclusão social, a função de perda do modelo otimizará a reprodução dessas mesmas assimetrias sob o verniz de "imparcialidade matemática". 2. **A Opacidade da Caixa-Preta (*Black Box*):** * Em modelos de bilhões de parâmetros, é matematicamente impossível rastrear com exatidão por que um peso específico tomou determinada decisão. Delegar decisões avaliativas ou pedagógicas cegas à IA sem auditoria humana gera injustiça e alienação docente. 3. **A Perda da Autonomia Cognitiva:** * A terceirização do pensamento crítico para sistemas preditivos enfraquece a iniciativa intelectual dos estudantes e

o discernimento clínico do educador. O princípio **Human-in-the-Loop** exige que a máquina seja ferramenta de rascunho, jamais árbitra soberana da sala de aula.

O Funcionamento Técnico da LGPD no Treinamento de Modelos

- Em plataformas abertas (OpenAI, Google, Anthropic em planos gratuitos standard), os diálogos submetidos via interface web são gravados em logs corporativos e utilizados em pipelines de **Fine-Tuning e RLHF**.
- Se um professor insere *"O aluno Gabriel Souza do 8º B tem laudo de TDAH e tirou nota 2"*, esses dados pessoais sensíveis (Art. 5º da Lei 13.709/2018) podem ser indexados em futuros modelos, vazando a privacidade da criança sem consentimento legal dos responsáveis.
- **O Chat Temporário / Opt-Out:** Bloqueia a persistência desses dados na base de treino e desativa a personalização baseada em histórico anterior.

---

13. Slide 32: O Embasamento Científico dos Artigos Citados (ArXiv e PMC)

Os dois artigos acadêmicos oficiais linkados no Slide 32 fundamentam toda a estrutura curricular do Encontro 2:

1. **Artigo ArXiv — https://arxiv.org/html/2306.04528**
   * **Título / Escopo:** Pesquisa avançada sobre o funcionamento interno das LLMs, a arquitetura de autoatenção dos Transformers e a emergência do raciocínio estruturado via *In-Context Learning* e *Chain of Thought*. * **Relevância para a Aula:** Comprova matematicamente que o modelo não é um banco de dados relacional, mas um sistema dinâmico auto-regressivo cuja coerência depende da qualidade do condicionamento de entrada (o prompt).
2. **Artigo PubMed Central (PMC) — https://pmc.ncbi.nlm.nih.gov/articles/PMC12396994/**
   * **Título / Escopo:** Avaliação científica sobre a eficácia de estruturas padronizadas de Engenharia de Prompts na prática profissional e formacional. * **Relevância para a Aula:** Demonstra através de ensaios empíricos com especialistas que prompts estruturados (com papéis definidos, restrições negativas, delimitação de formato e exemplos demonstrativos) reduzem as taxas de alucinação factual de mais de 35% para menos de 4% em tarefas analíticas complexas.

🎓 Síntese para a Docência

Compreendendo esses fundamentos, você docente nunca será surpreendido por uma pergunta técnica da turma. Quando um aluno perguntar *"por que a IA inventou isso?"*, você responderá com a física dos tokens, a matriz de autoatenção e a divergência estatística; quando perguntar *"por que*

preciso dar exemplos?", você explicará o meta-gradiente do In-Context Learning. Esse é o diferencial de uma formação rigorosa e verdadeiramente transformadora!